研析

本地GPU科研辅助系统

技术方案与实现说明 · 初稿

从文献原件到可回看的证据，再到检索、问答、阅读与研究写作。

4张GPU	20篇 / 100边	15 / 15页	145项
本地模型设备	固定引用图谱样本	官方扫描件OCR	后端行为测试

文档日期：2026-10-30

实现基线：306ef6f

团队名称 / 成员 / 学校与学院：信息待补

状态：工程初稿，公网与材料最终验收尚待完成

各数字对应不同测试范围，正文分别列出证据及限制；不构成项目整体完成率或通用性能承诺。

文档导航

摘要 3

1. 需求与设计目标 3

2. 系统架构与数据流 3

3. AI 技术选型、集成与优化 4

4. 六个业务模块实现 5

5. 有界研究任务 6

6. 技术与应用创新设计 6

7. 测试方法与实际结果 6

8. 部署、访问控制与复现 7

9. 限制与后续工作 8

10. 团队、贡献与资料管理 8

11. 仓库证据索引 8

12. 主要开源来源与许可 9

阅读提示：先看系统架构与AI方案，再结合测试结果审查实现范围。本文中的研究计划、确定性归纳和模型输出分别说明，不把计划当实验结论。

技术方案初稿 | 2026-10-30 | 源码基线：306ef6f

团队名称、成员姓名、学校／学院：**信息待补**。本文按已保存的实现和验收记录编写；引用编号对应文末仓库证据。本稿用于技术审阅；视频与公网演示分别验收，正式提交前还需补齐团队信息。

摘要

研析面向阅读、整理和比较科研文献的连续操作，提供从 PDF 入库、检索问答到引用回看、研究计划生成的本地工作台。系统采用 React 与 FastAPI，使用 SQLite 保存文献、逐页正文、向量及任务状态，在四张 RTX 2080 Ti 上运行 Qwen2.5-7B-Instruct、multilingual-e5-small 与 EasyOCR。模型只读取本地权重；论文检索和下载访问 arXiv 官方服务，推理不调用云模型。

系统以可回看的原文作为输出依据：回答附物理页码和摘录，摘要综述检查所选文献覆盖，引用网络保存参考文献位置，任务失败保留检查点。验证分别覆盖隔离行为测试、真实模型样例、PDF 身份与证据区间，以及独立 GPU 环境复现。结果说明既定链路可以运行，不构成通用准确率、零幻觉或全部需求完成的证明。

1. 需求与设计目标

科研阅读常涉及多种 PDF 版本、扫描件、中英文术语及跨论文对比。单独生成一段答案不能解决来源确认、版本误用和结果复查的问题，因此本项目将文献身份、原文定位和模型输出放在同一工作流中。

核心需求有四项：一是保留原文件，管理解析状态和相似版本；二是从明确文献范围检索证据，回答后能回到物理页；三是衔接检索、翻译、图谱和研究计划，减少重复操作；四是在既有显卡条件下部署，并保留运行、失败和恢复的证据。验收同时关注成功路径及拒答、归档、版本冲突、模型未就绪等边界。

产品采用单实例、共享文献库的部署方式，优先服务少量用户的研究操作，不以高并发平台为目标。已有解析正文导航和来源检查，但不将其表述为完整 PDF 排版理解、学术事实审查或自主科研代理。需求范围与已知边界分别见证据[1]、[3]。

2. 系统架构与数据流

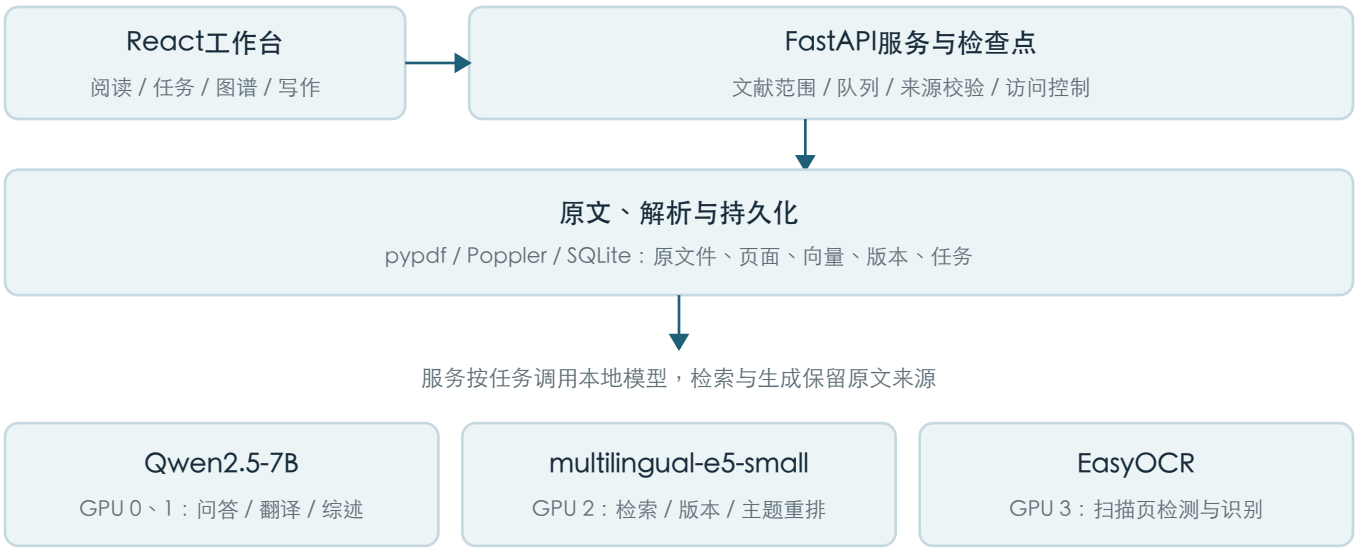


图1 服务层、原文持久化与四卡模型调用关系。PDF解析调用OCR，混合检索调用E5，生成任务调用Qwen。

前端负责文献选择、任务状态、正文阅读、结果编辑与导出；FastAPI 提供上传、解析、检索、推理及来源检查接口。原始 PDF 以文件 SHA-256 标识，SQLite 保存文献元数据、物理页正文、解析方式、坐标、切块向量、来源及任务记录。页面和 API 同源提供，减少部署配置分散。

主处理链如下：

```
PDF → 文本层／OCR → 按页切块与E5编码 → 版本候选／确认
确认有效版本 → E5 + BM25混合检索
问题 → 检索词扩展 → RRF 证据合并 → 本地回答 → 来源检查 → 原页回看
```

逐页解析采用单工作线程和有界排队；模型请求共享推理锁，避免多个任务同时挤占模型显存。原文、解析结果和缓存分开保存，重启后读取持久化数据。归档或版本替换不会删除原件，也不会把待确认版本混入问答。写作、图谱和导航使用文献快照或指纹，原文变化后要求重新核对。[1]

3. AI 技术选型、集成与优化

3.1 模型分工

组件	本地模型／精度	四卡分工
问答、检索词转换、翻译与计划	Qwen2.5-7B-Instruct，FP16	GPU 0、1 分片
中英文语义检索	multilingual-e5-small，FP32	GPU 2
扫描页文字识别	EasyOCR 英中识别	GPU 3

这一组合复用同一生成模型完成多种语言任务，以较小向量模型承担召回，以独立 OCR 处理无文本层页面，适配现有四张 11 GB 显卡。选型依据是本地运行条件与已完成集成，并未进行足以证明最优性的模型横向评测。启动使用离线加载选项，模型文件清单另存 SHA-256；下载权重属于准备阶段。[1][2]

3.2 检索与回答约束

页面按约 1100 字符切块，重叠 160 字符，保留页码和偏移。E5 使用 query／passage 前缀，向量归一化后持久化；BM25 补充术语和精确词匹配，再以 RRF 合并前六段证据。中文问题可由本地模型扩展检索词，明确图号、训练硬件或比较维度时，有限规则补充相应正文，而非依赖模型记忆补数。[1][4][5]

生成结果采用逐条结论和单一来源编号。服务端拒绝范围外编号，检查摘录是否匹配当前原文、结论中的阿拉伯数字是否在对应摘录出现，并返回真实文献与页码。摘要综述分篇生成后合并，要求纳入范围全部覆盖。这些措施使可检测的引用和数值错误显式失败，但数字存在不等于语义成立，仍需阅读原文。

3.3 资源与稳定性优化

实机 FP16 eager 注意力曾出现非有限数值，改用 SDPA 后恢复；没有以该显卡不支持的 BF16 或 FlashAttention 为运行前提。分卡加载、单进程服务、推理互斥和有界队列控制资源占用。翻译与下载采用缓存及检查点，避免重复处理已通过的内容。取消在当前推理段或已提交的单篇操作结束后生效，不强杀模型线程。独立 GPU 复现确认了实际执行，而非仅以就绪状态代替运行证据。[2]

4. 六个业务模块实现

4.1 文献解析与版本管理

上传后先核对文件头、大小和 SHA-256，改名上传相同字节仍复用原文献。当前单文件上限 100 MB、650 页。原生页面用 pypdf 提取；缺少可靠文本层时走本地 OCR，并保存文字、坐标、置信度及警告。正文词组与 E5 相似度产生版本候选，用户选择保留两版、保留旧版或替换旧版，决策留下记录，归档可恢复。

已对 541 页教材进行原件哈希、完整索引及逐页解析结果一致性核对，并保留数学字体与复杂内容警告。完整页数不表示图表、公式全部结构化。资料目录有 39 份 PDF 清单，当前测试不覆盖每份文献的所有问题，更不能由若干扫描样例推导 OCR 准确率。[3]

4.2 有证据的文献问答

用户明确选择文献范围后，系统仅检索有效、已就绪且未归档的正文。通用问题走本地检索与 Qwen；能够严格核对的结构问题采用保守处理器。例如作者序号须与首页线性署名一致，机构缺失时不由邮箱猜测；BLEU 表格按列坐标读数，差值单独标注计算；双篇编码器／解码器对比可由明确原文作确定性归纳。

官方样例曾出现作者顺序错误和硬件段漏召回，修复后五个固定问题及八项补充检查通过。GPT 参数、上下文和归一化比较分别取证，避免把不同论文数字拼到同一来源。确定性处理器与模型路径在报告中分开，不把规则答案计作生成模型通过。[4][5]

4.3 沉浸阅读与对照翻译

阅读界面并排展示原页和解析正文，支持显式编号三级章节导航，以及数字制、有限英文作者年份制的正文引用与书目双向定位。链接保存物理页、字符区间和页哈希；歧义年份、未知编号和无法可靠切分的书目不自动连接。当前交互发生在解析正文，尚无 PDF.js 图像上的文字覆盖层。

翻译按源段编号对照，双向滚动可联动。数字、可识别公式、代码和网址先保护再恢复；校验失败缩短或拆分重译，仍失败则中断并保留通过段落。Ragas 八页、39 段的真实翻译与导出已有记录；这不是通用语义质量评测，541 页教材的全量翻译仍未验收。[6][9]

4.4 论文检索与来源入库

arXiv 查询限定官方元数据与 PDF 来源，设置请求间隔、大小和下载预算。中文主题先转换为英文，E5 可按当前主题重排首批最多八个候选，保存官方原序号、相似度与选择方式；无向量模型时退回明确标注的官方顺序。相似度不是相关概率或论文质量评分，也不表示全库召回。

入库复用下载和解析队列，保留实际 arXiv 版本与来源。官方元数据用于 arXiv 题名，原文件不改写。过期缓存可提示查看，但不能作为自动导入的有效依据。当前实现不包含定期追踪、用户反馈学习和论文代码质量验证。[7]

4.5 引用图谱与研究线索

图谱在参考文献区间匹配完整题名、arXiv 编号或 DOI，跨页保存证据；正文普通提及不直接构成引用边。同作品版本合并后计算局部入度、出度与 PageRank。题名边界用于排除 RMSNorm 题名后缀误连 LayerNorm，附录边界用于避免把后续正文当书目。

20 篇、816 页样本形成 100 条有向边；人工复核候选中的 100 个正例覆盖、两个混淆负例拒绝。该集合没有盲审全部 380 个有向对，因此不能写成一般引用召回率。局部排名仅反映当前网络，不等于全球影响力。

Future Work 保留原文线索，不声称已判断其是否被新研究解决。[8]

4.6 研究计划与可视化

写作工坊根据研究设想和最多六篇作品的明确摘要，生成可编辑研究计划、相关工作和真实书目。已有结论与拟开展方法、评估计划分开；References 由服务端元数据组织，不让模型自由补造 DOI 或作者。原文指纹变化后旧来源检查失效，手改内容标明编辑状态，不沿用生成时的检查结论。

方法步骤可导出 Mermaid 与 SVG；标签作为数据转义，不执行生成代码。图表支持真实两列 CSV、柱状／折线图和 SVG 导出，尚无多维统计分析。研究计划不是完成实验的论文，也不证明新颖性。部分浏览器导出按钮已触发，但标准浏览器落盘仍需最终复核。[10]

5. 有界研究任务

任务将“主题检索-候选选择-逐篇入库-等待解析-摘要综述”串联，最多三篇、一个活动任务。SQLite 保存原始查询、候选、下载任务、文献身份、过程和结果。版本冲突暂停为待确认；模型未启动、缺摘要或覆盖校验失败时保留文献并进入待生成综述，可从检查点重试。服务重启不会隐式重新下载或推理。

中文主题“检索增强生成的自动评估”真实执行后，E5 在当前页选中官方第 4、6 名，分别为 45 页和 7 页文献。报告摘要位于物理第 5 页，旧首页规则漏检；覆盖检查拦截后，改为在前八页寻找明确摘要并排除目录项，最终两条结论分别回到第 5、1 页摘要。重试复用下载身份，旧 RAG 任务也成功补生成。此结果是一次主题样例，不是自主规划、完整会话记忆或完整 Agent。[7]

6. 技术与应用创新设计

技术层面，第一项特点是统一文献身份、物理页、原文区间和快照，让问答、导航、图谱与写作共享可追溯依据；第二项是模型生成与有限确定性处理器分工，能严格读取的作者序号、表格数值与明确架构事实优先核对；第三项是多篇摘要覆盖检查及检查点恢复，来源不足时保留数据并拒绝半份综述。

应用层面，检索到的文献可直接进入阅读、翻译、关系浏览和研究计划，任务状态与版本确认避免用户重复搬运资料。四卡本地部署则把外部论文获取与内部推理分开。这些属于集成、交互与可靠性方面的工程设计，未提出新的训练算法，没有自行训练基础模型，也不主张领先现有科研工具或达到 SOTA。对应实现及测试见证据[1]、[6]-[10]。

7. 测试方法与实际结果

测试分为隔离行为测试、真实数据验收和环境复现三层。隔离测试使用替身验证路由、状态和拒绝条件，不冒充模型能力；真实样例检查模型输出及原文；复现检查独立代码和包环境是否能执行同一处理链。源码基线的后端测试共 145 项、前端工具测试 5 项通过，另有生产构建与格式检查。[1][11]

验证范围	已记录结果	解释边界
独立四卡模型栈	原生 15 页 + 扫描 15 页 + BERT 16 页，共 46 页；162/162 段向量	三份指定 PDF，不是全部资料

验证范围	已记录结果	解释边界
真实 Qwen 问答	原生／OCR 均回答 FFN 为 2048，引用物理第 5 页	约 4.28／2.77 秒，仅样例耗时
双篇架构对比	各自引用第 3 页，区分编码器与解码器	确定性归纳，不计作 LLM 测试
20 篇图谱回归	100 正例、2 负例、162 个原文区间及排名核对	候选基准，不是通用准确率
本机 HTTPS 访问	72 项检查通过	不替代公网或浏览器验收

GPU 环境由固定源码导出，独立虚拟环境安装 90 个锁定依赖，核对 28 项模型文件 SHA-256。向量均为 384 维 FP32、每条 1536 字节；原生、扫描、BERT 分别有 47、43、72 段，直接查库核对，非仅看 health。依赖来自经校验的本机缓存重建安装，复用了 OS、驱动、解释器与模型文件，不是全新主机冷下载证明。[2]

正式库另发现 HellaSwag 的早期 CPU 导入缺 63 段向量。备份后通过正常重解析补齐，核对原 PDF、14 页正文哈希及 33 份文献的状态、归档与有效版本选择保持一致；有效 ready 文献已无缺失向量。此维护与隔离 GPU 实验分别记录，不能合并成同一次测试。[12]

8. 部署、访问控制与复现

部署采用 Python 3.12、Node.js 22.18 以上和匹配的 GPU 环境。先按锁定依赖安装，构建前端，下载并核对外置权重，再在环境变量中配置模型与数据目录。模型、PDF、数据库和实际密钥不进入 Git。正式服务单进程运行，可由用户级 systemd 管理；变更前备份数据，结束无任务时停止服务释放 GPU。[1][2]

8.1 安装与启动步骤

Ubuntu 服务器先准备 Python 3.12、Node.js 22.18 以上、匹配的 NVIDIA 驱动与 Poppler（pdftoppm）。在项目根目录执行：

```
uv venv --python 3.12 .venv
uv pip install --python .venv/bin/python \
  -r backend/server-environment.lock.txt \
  --extra-index-url https://download.pytorch.org/whl/cu130
npm ci
npm run build
cp .env.example .env
```

准备阶段可用 scripts/download_models.py 下载 Qwen 与 E5、scripts/download_ocr.py 下载 OCR，或复用已核对的外置文件。按模型清单核对哈希后，在 .env 设置三个模型的绝对路径、E5 的 cuda:2、OCR 的 cuda:3，以及 YANXI_LLM_SHARD=1。源码中的 Qwen 分片配置使用 GPU 0、1；保持四卡可见且编号对应，再执行 bash scripts/serve.sh。下载阶段联网，服务启动后只读本地权重。[1][2]

验收先检查 /api/health 的三类模型状态，再执行隔离库 GPU 脚本并核对实际回答、页码和向量，不将 health 代替功能验证。独立复现的具体命令见证据[2]；现有生产库不作为空库测试目标。

8.2 访问控制与运行维护

共享评审账号为可选配置，开启时页面、API、PDF、原页与接口文档都先认证。密码保存为随机盐 scrypt 哈希，账号、哈希与访问源缺项会在模型加载前失败。修改及消耗模型的请求需要标记并检查来源，认证响应限制缓存和跨站嵌入。它不是多用户权限系统，账号持有人共享文献库和现有修改能力。[11]

仓库提供 Caddy 反代示例，预期由 HTTPS 入口转发到回环后端。本机 TLS 已验证匿名拒绝、跨源写入拒绝、认证上传、Range／HEAD 等行为；正式域名、证书、外网浏览器登录和长期保活尚待部署验收。此前 CPU 独立环境仅证明安装、解析与持久化，完整四卡验证另有记录，两者不互相替代。[11][13]

9. 限制与后续工作

当前主要限制为复杂公式、表格和署名版面的结构化不足；引用格式与 OCR 错字可能漏识别；来源和数值检查不覆盖完整语义。问答是单轮证据回答，没有长期对话记忆或流式输出；研究任务为固定有界流程，没有自主工具规划。图谱与写作主要依赖可识别书目和摘要，缺少全文相关工作审查及最新研究查新。

交付优先补齐新版浏览器交互、实际公网访问控制、标准浏览器导出、技术文档定稿及演示视频，再按失败样例扩充解析与语义验证。正式材料应对应同一真实提交版本，保留限制，不将计划写成既有能力。当前初稿不代表项目全部需求或交付物已经完成。

10. 团队、贡献与资料管理

团队名称、成员姓名、学校、学院、指导信息及正式分工均为**信息待补**，由项目负责人确认。已知 GitHub 账号为 xxmazz。用户提供需求、资料与服务器并作产品决策；AI 辅助完成方案、代码、脚本和文档，实际人工与工具贡献按协作记录说明。[14]

原始论文按合法取得的文件使用，公开仓库主要保存程序、哈希清单和脱敏结果，不分发私人 PDF、完整数据库或模型权重。代码保留实际提交历史，不回填不存在的实验、开发时间或人员贡献。正式发布前仍需确认项目自身许可、演示资料授权和团队信息。

11. 仓库证据索引

下列记录有各自日期与基线；旧报告保留当时结果，不把历史测试数量相加为当前测试总量。JSON 中的身份、坐标和哈希用于复核，原文仍须由使用者自行取得。

- [1] 本地模型后端、后端验证、模型文件清单。
- [2] GPU 独立复现、GPU 实测记录。
- [3] 官方样本与边界、长文档记录。
- [4] 作者与硬件问答、五问及补充记录。
- [5] 表格与跨篇问答、比较记录、GPT 比较记录。
- [6] 阅读引用、作者年份记录、目录定位记录。
- [7] 研究任务、中文 GPU 任务记录、检索实现。
- [8] 20 篇图谱方法、固定候选、后续图谱回归。

- [9] 翻译实现、翻译记录。
- [10] 写作实现、写作记录。
- [11] 访问控制设计、本机 HTTPS 记录。
- [12] 正式库向量修复。
- [13] 基础独立复现、基础复现记录。
- [14] AI 协作记录、开发记录、月底交付清单。

12. 主要开源来源与许可

项目集成以下真实上游组件，模型和库的能力归属于各自作者。下表为主要来源，完整依赖版本见 package-lock.json 与 backend/server-environment.lock.txt；分发时须保留对应版本的许可及第三方声明，不能把下表视为完整依赖审计。

上游项目与许可来源	本项目用途	上游许可
Qwen2.5-7B-Instruct	本地语言生成	Apache-2.0
multilingual-e5-small	语义向量	MIT
EasyOCR	扫描文字识别	Apache-2.0
PyTorch	GPU 推理运行时	BSD 三条款及随附声明
Transformers	模型加载与生成	Apache-2.0
FastAPI	后端接口	MIT
pypdf	PDF 解析	BSD-3-Clause
NetworkX	网络分析	BSD-3-Clause
React	前端交互	MIT
TypeScript	类型与构建检查	Apache-2.0
Vite	前端构建	MIT

Markdown 预览另使用 MIT 许可的 react-markdown 与 remark-gfm，具体来源见依赖说明。系统工具和传递依赖按安装版本保留其许可。本项目没有将上游模型、通用算法或开源模块声明为自行原创。